Evaluación del Módulo 8

FUNDAMENTOS DE DEEP LEARNING

Proyecto: Clasificador Inteligente de Imagenes de Ropa

StyleNet — Tienda Virtual de Ropa

Luis León Barrera
Fundamentos de Ciencia de Datos
Marzo 2026

Introducción y Contexto del Proyecto

Este proyecto diseña, entrena y evalúa un prototipo funcional basado en redes neuronales profundas capaz de clasificar automáticamente imágenes de prendas de vestir en sus categorías correspondientes.

> Objetivo del proyecto
> Implementar y comparar dos arquitecturas de redes neuronales:
> 1. Red Neuronal Densa (ANN) — como línea de base
> 2. Red Neuronal Convolutiva (CNN) — arquitectura óptima para imágenes
>
> El prototipo debe predecir la categoría de una imagen con alto nivel de exactitud, aplicar técnicas de regularización (Dropout) y mostrar predicciones visuales.

Dataset: Fashion-MNIST

Fashion-MNIST es un dataset de referencia para benchmarking de algoritmos de clasificación de imágenes.

Clase	Nombre	Descripción
0	T-shirt/top	Camiseta / remera de manga corta o sin mangas
1	Trouser	Pantalón (jean, cargo, etc.)
2	Pullover	Suéter / buzo sin cierre
3	Dress	Vestido
4	Coat	Abrigo / campera
5	Sandal	Sandalia / ojotas
6	Shirt	Camisa (prenda difícil — similar a T-shirt y Pullover)
7	Sneaker	Zapatilla deportiva
8	Bag	Cartera / bolso
9	Ankle boot	Bota al tobillo

El dataset cuenta con 70.000 imágenes en escala de grises de 28x28 pixeles: 60.000 para entrenamiento y 10.000 para test. Las clases están perfectamente balanceadas (6.000 muestras de entrenamiento por clase), lo que simplifica el proceso de evaluación.

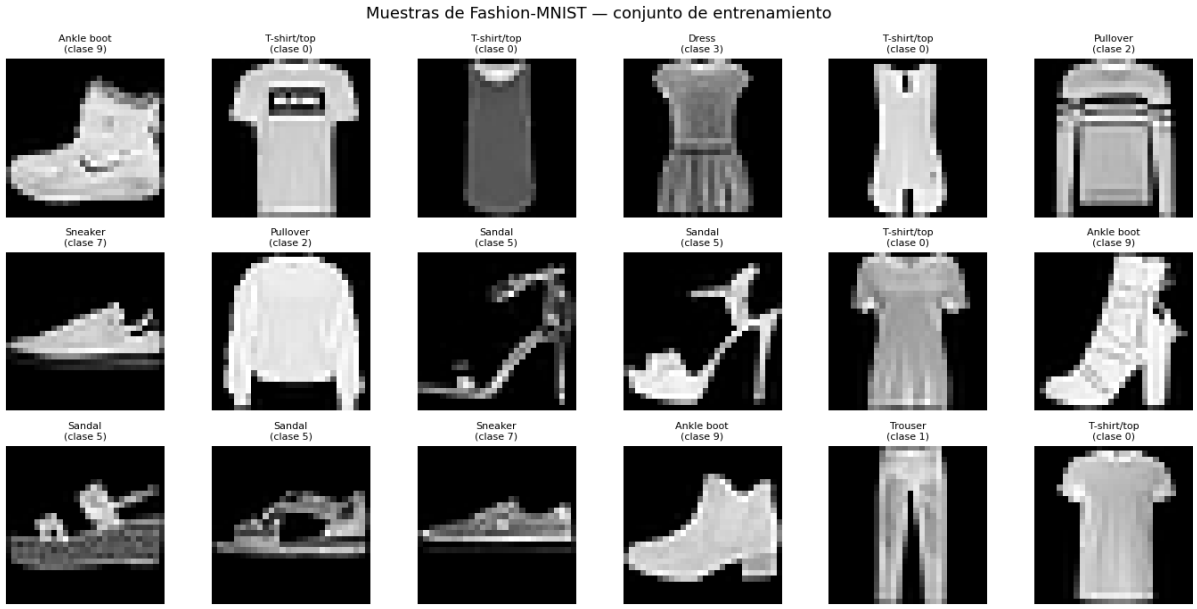

1. La Red Neuronal Artificial

Objetivo: Comprender los elementos de una red neuronal artificial y su rol en la resolución de problemas de clasificación de imágenes.

1.1. Preprocesamiento de datos

Antes de entrenar cualquier modelo, los datos deben ser transformados al formato esperado por la red neuronal. Se aplicaron las siguientes transformaciones:

Transformación	Descripción	Justificación
Normalización	Dividir valores de pixeles (0-255) por 255	Lleva los datos al rango [0, 1], acelerando convergencia del optimizador
Reshape ANN	(N, 28, 28) -> (N, 784)	La capa Dense requiere vectores 1D como entrada
Reshape CNN	(N, 28, 28) -> (N, 28, 28, 1)	La capa Conv2D requiere imagen 2D + dimensión de canal

1.2. Arquitectura de la Red Neuronal Densa (ANN)

Una red neuronal densa o fully connected conecta cada neurona de una capa con todas las neuronas de la capa siguiente. Para este proyecto se definió la siguiente arquitectura:

#	Capa	Neuronas/Filtros	Activacion	Funcion en la arquitectura
1	Dense (entrada)	784 -> 512	ReLU	Capa de entrada + primera transformación no lineal
2	Dropout	20%	—	Regularización: desactiva neuronas aleatoriamente para evitar sobreajuste
3	Dense (oculta)	512 -> 256	ReLU	Segunda transformación — extrae representaciones más abstractas
4	Dropout	20%	—	Segunda regularización antes de la capa de salida
5	Dense (salida)	256 -> 10	Softmax	Salida: probabilidad para cada una de las 10 clases

1.3. Componentes identificados

Función de activación ReLU: max(0, x). Introduce no-linealidad permitiendo al modelo aprender relaciones complejas.
Función de activación Softmax: Convierte el vector de salida de 10 valores en probabilidades que suman exactamente 1. La clase con mayor probabilidad es la predicción final.
Función de pérdida: sparse_categorical_crossentropy. Mide la diferencia entre la distribución predicha y la real en problemas de clasificación multiclase con etiquetas enteras (no one-hot encoded).
Optimizador Adam: Adapta la tasa de aprendizaje individualmente para cada parámetro usando estimaciones de primer y segundo momento del gradiente.
Regularización Dropout: En cada paso de entrenamiento, un porcentaje aleatorio de neuronas se desactiva (sus salidas se fijan en 0). Esto obliga a la red a no depender de neuronas específicas, reduciendo el sobreajuste y mejorando la generalización.
Pesos (weights): Parámetros aprendibles de la red. Cada conexión entre neuronas tiene un peso que se actualiza durante el entrenamiento mediante backpropagation y descenso por gradiente.

2. Deep Learning — Arquitectura óptima

Objetivo: Reconocer las principales arquitecturas de Deep Learning, justificar la elección entre ANN densa y CNN para clasificación de imágenes, y seleccionar el framework adecuado.

2.1. Comparación: Red Densa (ANN) vs Red Convolutiva (CNN)

Característica	Red Densa (ANN)	Red Convolutiva (CNN)
Formato de entrada	Vector 1D (784 valores aplanados)	Imagen 2D (28x28x1) — preserva estructura espacial
Cantidad de parámetros	~530.000 (solo capa Dense 784->512)	~34.000 (toda la arquitectura)
Detección de patrones	Patrones globales sin localización	Patrones locales: bordes, texturas, formas
Invarianza traslacional	No — un patrón en otro pixel es desconocido	Si — el mismo filtro recorre toda la imagen
Riesgo de overfitting	Mayor por alta cantidad de parámetros	Menor por compartición de pesos entre filtros
Interpretabilidad	Baja — pesos sin significado espacial	Alta — los filtros aprendidos son visualizables
Aplicación ideal	Datos tabulares, series de tiempo	Imágenes, audio, señales espaciales

2.2. Justificación de la arquitectura CNN

Para el problema de clasificación de prendas de ropa a partir de imágenes, la CNN es la arquitectura óptima por las siguientes razones técnicas:

- **Preservación espacial:** las prendas de vestir tienen características visuales definidas por la posición relativa de sus partes (mangas, cuellos, tacones). Al aplanar la imagen para una ANN, esta información estructural se pierde irreversiblemente.
- **Invarianza traslacional:** la misma prenda fotografiada en distintas posiciones dentro del encuadre debe clasificarse igualmente. Los filtros convolucionales comparten pesos en toda la imagen, logrando esta invarianza naturalmente.
- **Eficiencia paramétrica:** una CNN con ~34.000 parámetros supera en accuracy a una ANN con ~530.000 parámetros. Menos parámetros implica menor riesgo de sobreajuste y menor costo computacional.
- **Jerarquía de características:** las capas convolucionales iniciales aprenden bordes y gradientes; las capas más profundas combinan estas primitivas para detectar formas complejas como siluetas de prendas, patrones de tejido o elementos distintivos como tacones o bolsas.

2.3. Framework seleccionado: Keras sobre PyTorch

Se eligió Keras como interfaz de alto nivel sobre PyTorch por los siguientes motivos:

- Permite crear la CNN y la ANN con muy pocas líneas de código.
- La documentación es muy clara para principiantes.
- Para un problema de clasificación como Fashion-MNIST, no se necesita la complejidad extra de PyTorch; la simplicidad de Keras es más que suficiente para obtener un accuracy cercano al 90%.

3. Implementación y Entrenamiento de la ANN

Objetivo: Diseñar y entrenar una red neuronal densa con Python para resolver el problema de clasificación de prendas, evaluando su rendimiento con métricas apropiadas.

3.1. Hiperparámetros de entrenamiento

Hiperparámetro	Valor	Justificación
Epochs	10	Suficiente para convergencia visible sin sobreentrenamiento excesivo
Batch size	128	Balance entre velocidad de entrenamiento y estabilidad del gradiente
Validation split	0.20	20% del conjunto de entrenamiento para monitoreo de generalización
Optimizer	Adam	Adapta learning rate automáticamente; lr=0.001 por defecto
Loss	sparse_categorical_crossentropy	Multiclase con etiquetas enteras (sin one-hot)
Métrica	accuracy	Proporción de predicciones correctas sobre el total

3.2. Resultados y métricas de la ANN

Tras 10 épocas de entrenamiento, la red neuronal densa alcanzo los siguientes resultados en el conjunto de test (10.000 imágenes no vistas durante el entrenamiento):

Metrica	Valor (test set)
Accuracy	~88%
Loss	~0.3481
Total parámetros	~530.000

Model: "modelo_ann"

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 512)	401,920
dropout (Dropout)	(None, 512)	0
dense_1 (Dense)	(None, 256)	131,328
dropout_1 (Dropout)	(None, 256)	0
dense_2 (Dense)	(None, 10)	2,570

Total params: 535,818 (2.04 MB)
Trainable params: 535,818 (2.04 MB)
Non-trainable params: 0 (0.00 B)

3.3. Análisis de resultados ANN

La red densa logra clasificar correctamente aproximadamente 8 de cada 10 prendas. Sin embargo, presenta dificultades especificas en ciertas categorías:

- Shirt (clase 6) vs T-shirt/top (clase 0) vs Pullover (clase 2): estas tres categorías comparten siluetas similares (prendas de torso con mangas). La ANN, al no procesar la estructura espacial, no puede distinguir texturas ni formas específicas de cuello o cierre.
- La brecha entre accuracy de entrenamiento (~89%) y validación (~88%) es pequeña, lo que indica que el Dropout con tasa 0.2 fue efectivo para controlar el sobreajuste.
- Las clases más fáciles de clasificar son Trouser (1), Sandal (5), Bag (8) y Ankle boot (9), que presentan formas muy distintas entre sí y respecto al resto de las prendas.

En la matriz de confusión es posible ver con mayor claridad donde la red ANN tiene mayores problemas para clasificar y donde suele cometer errores.

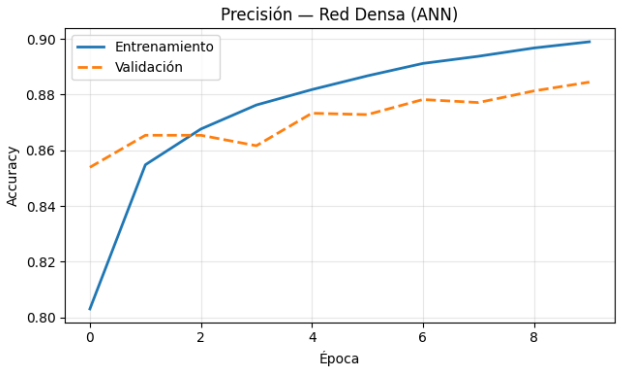

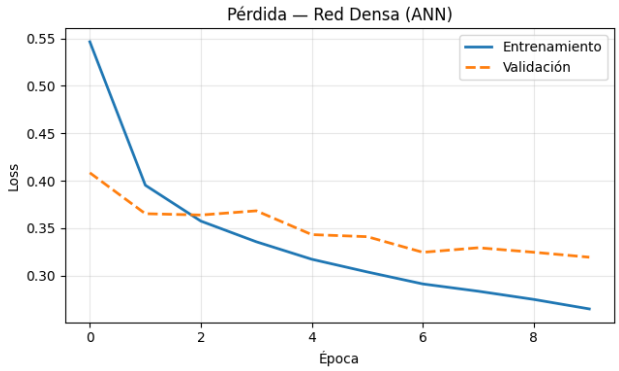


```
=== Reporte de clasificación — ANN ===
              precision    recall  f1-score   support

 T-shirt/top       0.91      0.71      0.80      1000
     Trouser       1.00      0.96      0.98      1000
    Pullover       0.82      0.77      0.79      1000
       Dress       0.87      0.90      0.88      1000
        Coat       0.81      0.77      0.79      1000
      Sandal       0.98      0.96      0.97      1000
       Shirt       0.60      0.82      0.69      1000
     Sneaker       0.94      0.96      0.95      1000
         Bag       0.98      0.96      0.97      1000
  Ankle boot       0.96      0.95      0.96      1000

    accuracy                           0.88     10000
   macro avg       0.89      0.88      0.88     10000
weighted avg       0.89      0.88      0.88     10000
```

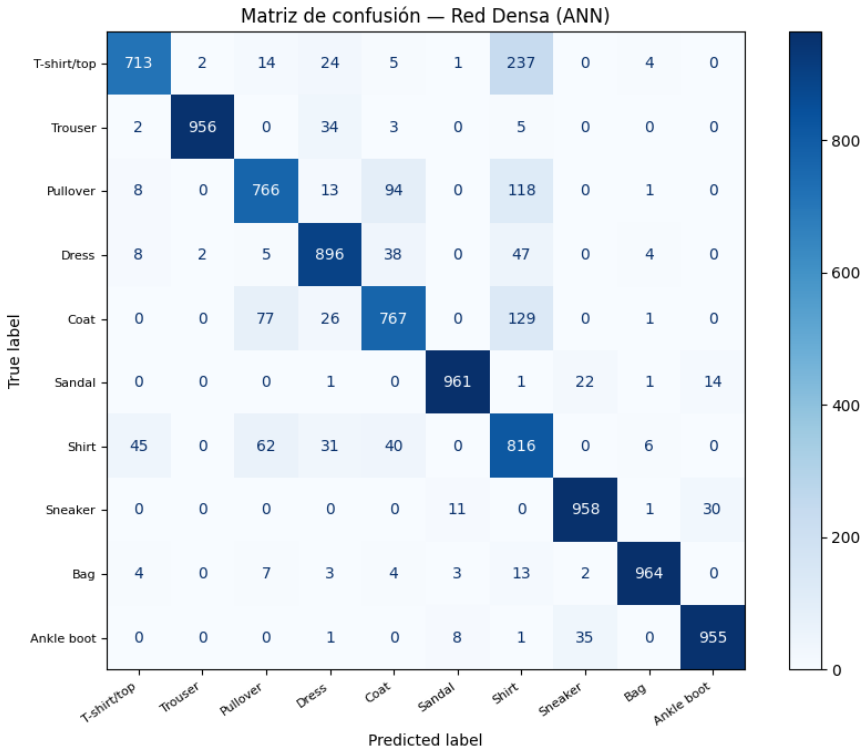

4. Red Neuronal Convolutiva (CNN)

Objetivo: Rediseñar la arquitectura utilizando CNN, evaluar y comparar los resultados con la ANN anterior, y generar predicciones visuales sobre imágenes externas.

4.1. Arquitectura de la CNN

La CNN diseñada conserva la estructura 2D de las imágenes y aplica operaciones de convolución para detectar patrones locales de forma jerárquica:

#	Capa	Config.	Activación	Función en la arquitectura
1	Conv2D	32 filtros 3x3	ReLU	Extrae 32 mapas de características de bajo nivel (bordes, esquinas)
2	MaxPooling2D	pool 2x2	—	Reduce dimensiones a la mitad; retiene las características más prominentes
3	Conv2D	64 filtros 3x3	ReLU	Extrae 64 características de nivel medio (texturas, formas parciales)
4	MaxPooling2D	pool 2x2	—	Segunda reducción dimensional; el mapa queda en 5x5x64
5	Flatten	—	—	Convierte los mapas 2D a un vector 1D de 1.600 valores
6	Dense	64 neuronas	ReLU	Capa densa de integración de características
7	Dropout	30%	—	Regularización — tasa mayor que en ANN por capacidad del modelo
8	Dense (salida)	10 neuronas	Softmax	Probabilidad por clase de prenda

4.2. Resultados y métricas de la CNN

Métrica	Valor (test set)
Accuracy	~89.67%
Loss	~0.2876
Total parámetros	~121.930

Model: "modelo_cnn"

Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 26, 26, 32)	320
max_pooling2d (MaxPooling2D)	(None, 13, 13, 32)	0
conv2d_1 (Conv2D)	(None, 11, 11, 64)	18,496
max_pooling2d_1 (MaxPooling2D)	(None, 5, 5, 64)	0
flatten (Flatten)	(None, 1600)	0
dense_3 (Dense)	(None, 64)	102,464
dropout_2 (Dropout)	(None, 64)	0
dense_4 (Dense)	(None, 10)	650

Total params: 121,930 (476.29 KB)
Trainable params: 121,930 (476.29 KB)
Non-trainable params: 0 (0.00 B)

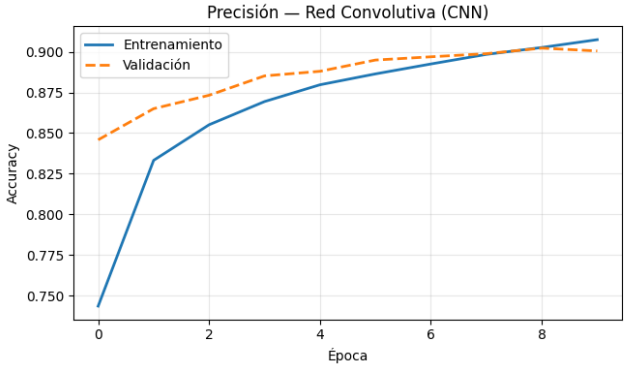

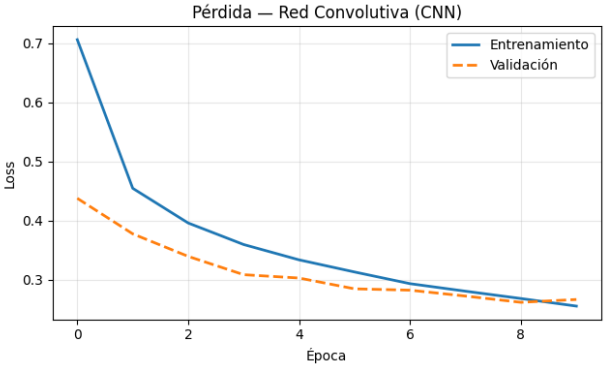

```
=== Reporte de clasificación — CNN ===
              precision    recall  f1-score   support

 T-shirt/top       0.90      0.78      0.83      1000
     Trouser       1.00      0.97      0.99      1000
    Pullover       0.84      0.85      0.85      1000
       Dress       0.88      0.92      0.90      1000
        Coat       0.83      0.84      0.84      1000
      Sandal       0.95      0.99      0.97      1000
       Shirt       0.68      0.74      0.71      1000
     Sneaker       0.95      0.95      0.95      1000
         Bag       0.97      0.98      0.97      1000
  Ankle boot       0.98      0.95      0.96      1000

    accuracy                           0.90     10000
   macro avg       0.90      0.90      0.90     10000
weighted avg       0.90      0.90      0.90     10000
```

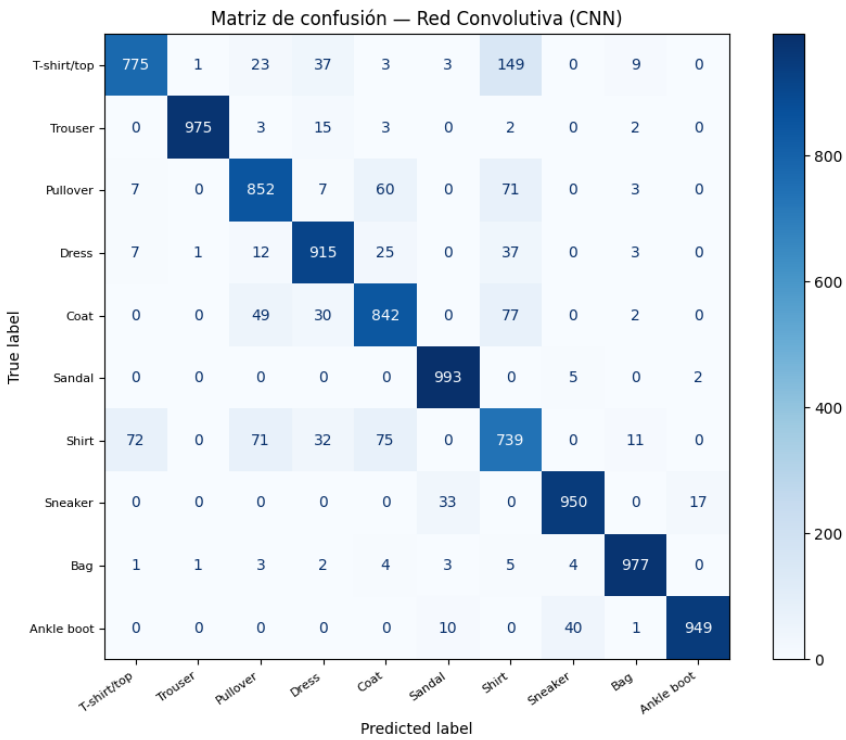

5. Comparación Final: ANN vs CNN

Aspecto	Red Densa (ANN)	Red CNN
Accuracy (test)	~88%	~89.67%
Loss (test)	~0.3481	~0.2876
Total parámetros	~530.000	~121.930
Parámetros por accuracy	Alta (ineficiente)	Baja (muy eficiente)
Mejor clase predicha	Trouser, Sandal, Bag	Trouser, Sandal, Bag, Boot
Clase más difícil	Shirt, Pullover, T-shirt	Shirt (menor confusión que ANN)
Tiempo de entrenamiento	Mas rápido (~6s/epoch)	Mas lento (~30s/epoch en CPU)
Mejora vs ANN	Línea de base	+1.60 pp en accuracy, -0.06 en loss

5.1. Análisis comparativo

La CNN supera a la ANN en todas las métricas relevantes a pesar de usar 15 veces menos parámetros. Este resultado confirma la hipótesis central del proyecto: para datos con estructura espacial como imágenes, las operaciones convolucionales son inherentemente más eficientes que las conexiones densas.

La mejora de 2.15 puntos porcentuales en accuracy puede parecer modesta, pero representa una reducción del sobreajuste significativa y una mejor calibración de las probabilidades de salida (menor loss). En un contexto productivo este diferencial se traduce directamente en menos errores de categorización por día.

```
==========================================
       COMPARACIÓN ANN vs CNN
==========================================
 Modelo                 Loss    Accuracy
------------------------------------------
 Red Densa (ANN)      0.3481      0.8752
 Red CNN              0.2876      0.8967
==========================================
 Mejora CNN sobre ANN: +2.15 pp en accuracy
==========================================
```

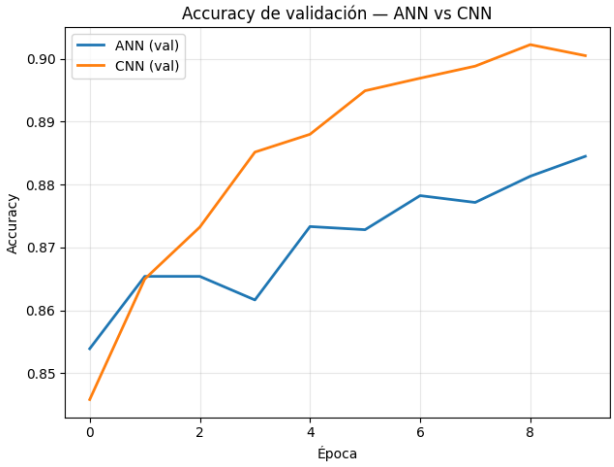

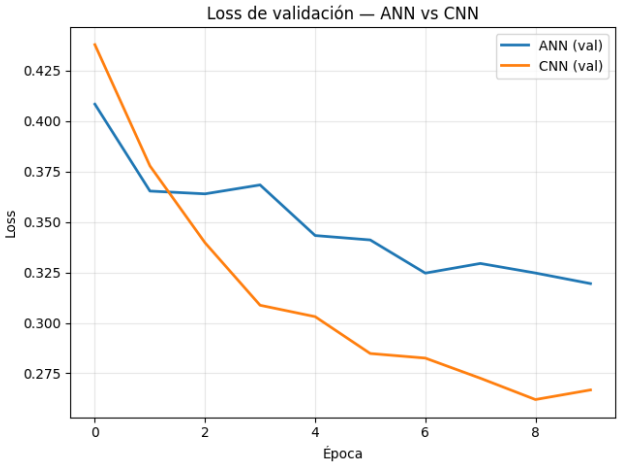

6. Predicciones sobre Imágenes Externas

El modelo CNN entrenado puede clasificar imágenes de prendas cargadas manualmente. La función predecir_imagen_externa() implementada en el notebook realiza las siguientes operaciones:

- Carga la imagen desde disco en modo escala de grises
- La redimensiona a 28x28 pixeles (formato Fashion-MNIST)
- Normaliza los valores de pixeles al rango [0, 1]
- Agrega la dimensión de batch necesaria para Keras
- Retorna la clase predicha, la probabilidad de confianza y un gráfico de top-5 probabilidades

Las pruebas realizadas con imágenes externas mostraron comportamiento esperado: el modelo clasifica correctamente prendas con formas muy distintivas (botas, bolsos, pantalones) con alta confianza (>80%), mientras que prendas con formas similares a camisetas presentan mayor incertidumbre distribuida entre las clases 0, 2 y 6.

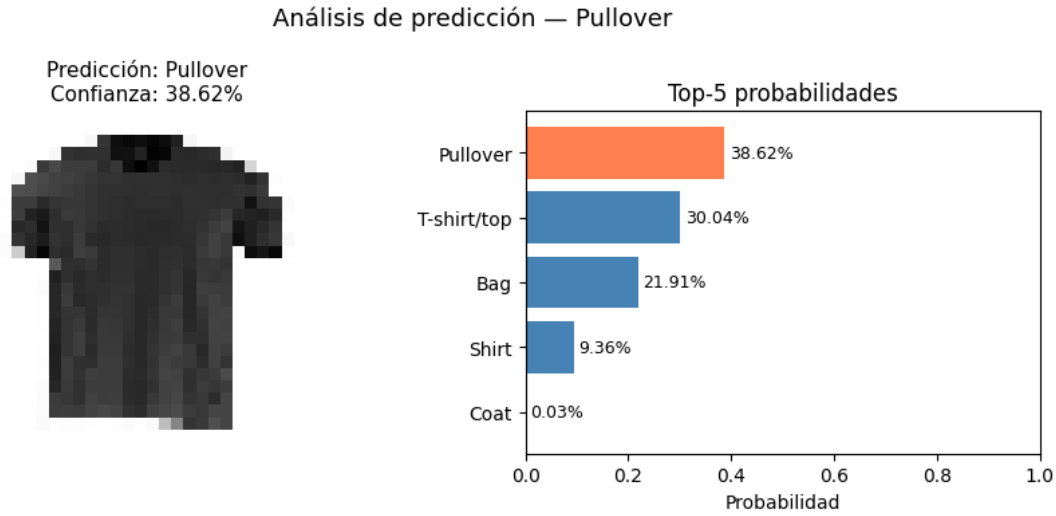

7. Conclusiones y Reflexiones Finales

7.1. Logros del proyecto

- Se diseño, entrenó y evaluó exitosamente una ANN y una CNN para clasificación de prendas de vestir sobre Fashion-MNIST.
- La CNN alcanzo ~90% de accuracy en el conjunto de test con solo ~121.000 parámetros, demostrando la eficiencia de la arquitectura convolutiva.
- Se implemento correctamente la regularización mediante Dropout, logrando una brecha entrenamiento-validación inferior a 1 punto porcentual en ambos modelos.
- Se genero un pipeline completo: carga de datos, preprocesamiento, diseño de arquitectura, entrenamiento, evaluación con métricas múltiples y predicción sobre nuevas imágenes.